

InternVL2.5-2B 多模态奖励模型训练与数据选择

摘要

本项目面向多模态奖励模型训练任务，选用 InternVL2.5-2B 作为基础视觉语言模型，在模型后端加入用于输出数值分数的线性 score head，并借助 RLAIIF-V 中的图文偏好数据进行训练。原始 InternVL2.5-2B 以生成式 judge 的形式在 VLRewardBench 上得到 46.51% 的 Score_base；训练后的主模型在 VLRewardBench full set 上得到 71.69% 的 Score_reward。

考核第一天晚间，raw RLAIIF-V 1024 条样本已经得到 74.66% 的 full benchmark accuracy。由于这个分数较高，后续实验重点转向数据审计和数据选择：检查 RLAIIF-V 与 VLRewardBench 之间的显式图像重复、近似图像、query 文本重合、response 文本重合以及 prompt 模板集中度，并设计 PromptCap 数据选择策略。最终主模型使用 RLAIIF-V 内部 prompt 频率限制得到的 4096 条训练样本，不使用 VLRewardBench 的样本、标签或候选回答作为训练内容。PromptCap50 在保持 70% 以上 full benchmark accuracy 的同时，降低了训练子集的高频 prompt 模板集中度。

1. 任务理解与完成情况

考核要求是以 Qwen2-VL 或 InternVL2.5-VL 系列模型为 base model，通过在模型后端添加 score head 的方式训练 reward model，并在 VLRewardBench 上得到 Score_base 和 Score_reward。同时需要保存模型权重，撰写实验报告，后续上传代码到 GitHub、上传权重到 Hugging Face。

本项目完成情况如下。

要求	本项目完成情况
选择推荐基础模型	使用 InternVL2.5-2B，模型规模小于 3B
得到 Score_base	原始 InternVL2.5-2B 生成式 judge：46.51%
添加 score head 并训练 reward model	实现 InternVL2.5-2B + LoRA + linear score head
得到 Score_reward	主模型 full VLRewardBench accuracy：71.69%
保存模型权重	保存 LoRA adapter、score_head_final.pt、training_meta.json
实验报告	本文整理了方法、数据处理、训练参数、实验发现和问题分析
不使用 VLRewardBench 数据训练	训练样本来自 RLAIIF-V；VLRewardBench 只用于评测和审计分析
不抄袭已有项目	核心训练、评测、数据选择和审计脚本为本项目实施

训练采用参数高效微调路线。基础 VLM 的原始权重保持冻结，训练 LoRA 参数和新增的 score head，将模型输出形式从生成回答转为候选回答质量打分。

整个实验从环境准备开始推进：先在 SCNet 超算互联网平台上整理 InternVL2.5-2B、RLAIIF-V 和 VLRewardBench 的本地路径，跑通 base judge 与 head-only 小样本链路，再扩展到 LoRA reward 训练、数据审计、PromptCap 数据选择、结构消融和稳定性诊断。最终结果既包含可提交权重，也包含对分数来源、数据边界和训练稳定性的复查。

2. 相关工作与实验动机

多模态 reward model 的核心目标是判断已有图文回答的质量。InternLM-XComposer2.5-Reward [2] 提供了一个直接参考：它基于视觉语言模型训练多模态 reward model，并用于强化学习监督信号、候选回答选择以及数据过滤等场景。该工作说明，保留 VLM 的图文表征能力，再通过偏好数据训练 reward 头，是一条实际可行的路线。

另一条对本项目更重要的线索来自 Skywork-Reward [1]。该工作强调 reward modeling 中的数据筛选、清洗和混合策略会显著影响最终效果。本项目的早期实验也给出同样信号：raw RLAIIF-V 1024 条样本可以得到很高分数，同时该子集的 prompt 模板集中度也很高。随后，实验主线转向训练数据审计和选择，并以结构消融作为辅助验证。

RLAIF-V [4] 关注开放模型反馈和多模态幻觉缓解，提供了包含图像、prompt、chosen response 和 rejected response 的偏好数据。VLRewardBench [3] 用于评测视觉语言生成式 reward model，覆盖一般多模态 query、视觉幻觉检测和复杂推理等场景。两者处在相近的多模态偏好判断生态中。本文的结果对应公开同域偏好数据下的 reward-model adaptation。

3. 模型方法

3.1 输入与输出

Reward model 每次只评价一个候选回答。输入由图像、问题和候选回答组成：

```
image + question + candidate response
```

模型输出一个数值分数：

```
reward_score = RM(image, question, candidate_response)
```

在 VLRewardBench 评测中，同一条样本有两个候选回答。模型分别计算两个回答的 reward score，分数更高的回答就是模型认为更优的回答。

Score_base 使用原始 InternVL2.5-2B 作为生成式 judge。评测时，将图像、问题和两个候选回答一起输入模型，prompt 要求模型从视觉准确性、完整性、清晰度和相关性几个方面判断哪一个回答更好，并输出类似 **Overall Judgment: Answer X is better.** 的结论。评测脚本会随机交换两个候选回答的展示顺序，再解析模型输出的 Answer 1 或 Answer 2，与 VLRewardBench 的 human_ranking 对齐后计算准确率。本项目采用 short-output judge prompt、max_new_tokens=32、max_tiles=2，在 full set 1247 条样本上得到 46.51%。Score_reward 使用训练后的 reward model 分别给两个候选回答打分，直接比较两个数值分数。

3.2 模型结构

主模型结构如下。

```
image + question + candidate response
-> InternVL2.5-2B
-> final valid-token hidden state
-> Linear(hidden_size, 1)
-> reward score
```

InternVL2.5-2B 负责图像和文本的联合表征。score head 是一个线性层，把最后一个有效 token 的 hidden state 映射为一个数值 reward score。最终主模型采用 linear head，这一选择来自后续结构消融：在相同训练框架下，MLP head 的 full benchmark accuracy 只有 50.44%，明显低于 linear head 对应结果。

3.3 训练目标

RLAIF-V 中每条训练样本包含 chosen response 和 rejected response。训练时分别计算：

```
score_chosen = RM(image, question, chosen_response)
score_rejected = RM(image, question, rejected_response)
```

损失函数采用 Bradley-Terry 形式的 pairwise preference loss：

```
loss = -log sigmoid(score_chosen - score_rejected - margin)
```

主实验中 margin 设为 0。训练目标集中在 pairwise ranking：提高 chosen response 相对 rejected response 的分数。

3.4 训练参数

主提交模型配置如下。

配置项	设置
base model	OpenGVLab/InternVL2_5-2B
训练方式	冻结原始权重，训练 LoRA adapter 和 score head
LoRA r	8
LoRA alpha	16
LoRA dropout	0.05
score head	linear
pooling	final valid token
training pairs	4096
epochs	1
learning rate	1e-4
max image tiles	2
seed	42
实验平台	SCNet 超算互联网平台，NVIDIA A800 80GB PCIe

LoRA 采用 **r=8**，**alpha=16**，**dropout=0.05**，属于小模型参数高效微调中较常用的保守配置。**r=8** 控制新增参数规模，**alpha=16** 使 LoRA 分支保持适中的缩放强度，**dropout=0.05** 用于抑制小规模偏好数据上的过拟合。该设置使训练成本保持在可控范围内，也支持在考核时间内完成多轮数据和结构实验。

4. 数据处理与相似性审计

4.1 数据审计动机

考核第一天晚间，raw RLAIIF-V 1024 条偏好样本已经在 full VLRewardBench 上得到 74.66%。这个结果说明 RLAIIF-V 对多模态偏好判断任务具有很强的训练价值，也提示后续实验需要继续追问分数来源。本文随后把工作重点转向训练子集和 benchmark 之间的任务相似性、显式重复风险以及 prompt 模板分布，以区分 reward model 训练范式、同域数据优势和训练子集内部模板分布带来的影响。

考核明确禁止使用 VLRewardBench 的数据训练，但训练数据不受限制。因此，合理的边界应当分成三层来看。

层面	含义	本项目处理
硬性训练边界	是否把 VLRewardBench 的样本、标签或候选回答作为训练样本	没有使用
显式重复	是否存在相同图片、近似图片、完全相同 query 或 response	做程序化审计
同域相似性	训练数据是否与 benchmark 属于相近任务生态	在结果解释和数据选择实验中单独讨论

这种分层有助于把合规边界和研究解释分开。视觉语言偏好数据中常见 “describe this image in detail” 之类通用 prompt，query 文本重合通常对应任务模板相似性，不能直接等同于训练样本重复。对于 reward model 来说，使用同域公开偏好数据是正常训练方式；本项目严格避免把 benchmark 样本、人工 ranking 或候选回答用于训练。

数据处理的核心目的，是在公开同域偏好训练的前提下，让训练边界和分布特征能够被复查。raw first 1024 给出了很强的同域适配结果；后续的 strict query+image、image-only refined 和 PromptCap 系列实验，分别用于观察显式相似性、图像近重复过滤和 prompt 模板集中度对结果的影响。

4.2 审计指标

本文对 RLAIIF-V 训练子集做了以下审计。

指标	含义
image MD5 exact overlap	检查是否存在完全相同图片
dHash near overlap	用感知哈希检查近似图片
query overlap rate	归一化后的 prompt/query 是否与 VLRewardBench query 完全相同
response exact overlap	chosen/rejected response 是否与 benchmark response 完全相同
unique prompt	子集中不同 prompt 数量
effective prompt	基于 entropy 的有效 prompt 数，数值越大表示 prompt 分布越分散
top20 prompt mass	出现最多的 20 个 prompt 占训练子集比例

在前 8192 条 RLAIIF-V 候选样本中，没有发现 image MD5 完全重合。dHash near overlap 只占少量样本，response exact overlap 极低。query overlap 较高，主要来自通用图像描述模板。这个结果支持两个判断：第一，审计中未发现训练集直接包含 VLRewardBench 样本；第二，RLAIIF-V 与 VLRewardBench 在任务模板和领域上确实相近，因此最终结果需要结合数据分布一起解释。

同时，RLAIIF-V 前 8192 条样本的 prompt 分布并不均匀：最高频 prompt 可出现两百次以上，top20 prompt mass 约为 41%。PromptCap 后续被引入，正是为了解决训练子集中少数高频模板占比过高的问题。PromptCap 不依赖 VLRewardBench 字段，只根据 RLAIIF-V 内部 prompt 频率控制每类模板的最大样本数。

4.3 PromptCap 数据选择

为使最终训练子集选择只依赖训练集内部信息，本文设计了 PromptCap。它只使用 RLAIIF-V 训练集内部的 prompt 频率，不读取 VLRewardBench 的样本内容来决定保留哪些训练样本。

PromptCap50 的规则如下。

- 1 按 RLAIIF-V 原始顺序扫描样本。
- 2 prompt 经过小写化和空白归一化后，完全相同的文本视为同一个 prompt。
- 3 同一个 prompt 最多保留 50 条样本。
- 4 达到 4096 条 preference pairs 后停止。

PromptCap 的目标是在同域训练前提下控制模板集中度。raw 子集中少数高频 prompt 占比很高，模型容易被这些模板支配；PromptCap 通过训练集内部的频率限制降低模板集中度，同时保留足够的同域偏好信号。

最终主模型选择 PromptCap50，没有直接使用 raw first 1024 的最高分结果。raw first 1024 更接近强同域适配上限，分数高，模板集中度也高；PromptCap50 将 top20 prompt mass 从 41.50% 降到 23.63%，effective prompt 从 216.31 提高到 811.89，同时仍保持 71.69% 的 full benchmark accuracy。本文因此将 PromptCap50 作为主提交模型。

5. 实验结果

实验部分按“先跑通、再审计、再选择、再消融”的顺序组织。第一步用 head-only 和 raw 1k LoRA 确认训练链路；第二步围绕 raw 1k 的高分做数据相似性和 prompt 分布审计；第三步比较 strict query+image、image-only refined 和 PromptCap 系列；第四步补充 pooling、MLP head 和 seed 诊断。这样可以同时回答三个问题：reward 训练是否有效，数据选择是否合理，结构改动是否真的带来收益。

5.1 总体结果

实验设置	训练数据策略	VLRewardBench accuracy	实验作用
InternVL2.5-2B base judge	无 reward 训练	46.51%	Score_base, 生成式 judge
Head-only v0	RLAIIF-V 128 pairs	47.79%	验证 score head 流程
Raw RLAIIF-V 1k	原始前 1024 条	74.66%	第一日晚间得到，促成后续数据审计


实验设置	训练数据策略	VLRewardBench accuracy	实验作用
Image-only refined 4k	近似图像过滤	66.72%	检查图像近重复过滤影响
Strict query+image 4k	query 与近图像审计过滤	70.17%	分析显式相似性影响
PromptCap50 4k	训练集内部 prompt cap	71.69%	主提交模型
PromptCap10 4k	训练集内部 prompt cap	70.73%	验证更强 prompt 分散化
PromptCap20 4k	训练集内部 prompt cap	60.63%	展示 prompt/source 组合的敏感性
MLP head PromptCap20 4k	MLP score head	50.44%	结构复杂化未带来收益

主模型的 Score_reward 为 71.69%，相比 Score_base 46.51% 提升 25.18 个百分点，也高于考核文档中给出的 InternVL2.5-2B-Reward 参考值 64.8%。结合前述数据审计，本文将这一分数解释为 InternVL2.5-2B 在公开同域偏好数据训练后，对 VLRewardBench 回答偏好判断任务的显著适配提升。

这张表也反映了实验推进顺序。Head-only v0 用来验证 score head 流程是否可用；raw first 1024 在 5 月 18 日晚间给出 74.66% 后，实验重心转向数据边界；image-only refined、strict query+image 和 PromptCap 系列用于拆分图像近重复、query 重合和模板集中度的影响；MLP head 与 pooling 消融用于判断结构复杂化是否值得继续投入。

5.2 数据选择实验


数据策略	effective prompt	top20 prompt mass	query overlap rate	accuracy
raw first 1024	216.31	41.50%	46.39%	74.66%
image-only refined 4096	407.21	40.16%	44.95%	66.72%
strict query+image 4096	1768.71	16.67%	0.00%	70.17%
PromptCap50 4096	811.89	23.63%	30.88%	71.69%
PromptCap20 4096	1733.88	9.77%	16.04%	60.63%
PromptCap10 4096	2440.44	4.88%	8.96%	70.73%



这组结果表明，prompt 多样性和最终准确率不存在简单的单调关系。raw first 1024 的 prompt 集中度最高，同时分数也最高；PromptCap10 的 prompt 分布最分散，仍有 70.73%；PromptCap20 则降到 60.63%。这说明 reward model


对 prompt/source 组合比较敏感：高频模板能提供强同域信号，过度依赖高频模板会削弱结果解释的稳健性；cap 过强或命中 source 分布的关键位置时，也会改变重要任务类型的训练比例。

PromptCap50 在数据分布和最终准确率之间取得了较好的平衡。它把 top20 prompt mass 从 raw first 1024 的 41.50% 降到 23.63%，effective prompt 从 216.31 提高到 811.89，同时仍能取得 71.69%。相比 strict query+image 的 70.17%，PromptCap50 的最终训练子集选择只依赖 RLAIIF-V 内部统计，因此被选为主提交模型。



5.3 Source-level 结果

VLRewardBench 的不同 source 难度差异明显。PromptCap50 在 POVID、COCO、OK-VQA 和 VQAv2 上表现较强，在 wildvision-battle 和空 source 上相对弱一些。



source-level 结果进一步解释了不同数据策略之间的差异。raw 1k 在 POVID、OK-VQA、GQA 等 source 上很强，同时具有最高的 prompt 模板集中度，体现了强同域适配带来的上限效果。PromptCap50 在 POVID 上达到 81.03%，COCO 为 82.54%，OK-VQA 为 87.50%，VQAv2 为 80.00%，说明适度降低 prompt 集中度后，模型仍保留了对主要 source 的判断能力。PromptCap10 的总体分数接近 PromptCap50，但 source-level 分布更不均衡：POVID 达到 88.84%，wildvision-battle 降到 52.05%，OK-VQA 降到 62.50%。这一结果说明，过强的 prompt cap 虽然仍能维持较高总体准确率，但会改变不同任务来源之间的性能分布。

5.4 结构消融

实验	数据	accuracy	结论
final-token pooling + linear head	PromptCap20 1k	61.03%	取最后一个有效 token 的 hidden state
final+mean concat pooling + linear head	PromptCap20 1k	60.14%	拼接 final token 与文本 mean pooling
MLP head	PromptCap20NoBench 4k	50.44%	明显低于 linear head

结构实验覆盖了两类改动：一类是 pooling，比较 final-token pooling 与 final+mean concat pooling；另一类是 score head，比较 linear head 与 MLP head。在当前数据规模和训练轮数下，复杂化 score head 没有带来收益。Reward model 的 score head 需要输出可比较的排序分数；当 head 表达能力增加而训练信号不足时，排序尺度更难稳定形成。linear head 更直接地利用了 backbone 的图文表征，因此成为最终主模型采用的结构。

5.5 训练稳定性诊断

为了检查单 epoch LoRA reward 训练对随机性的敏感程度，本文使用相同的 PromptCap50 indices 和相同训练配置，额外运行了一次 seed=123 诊断实验。该实验不作为主提交模型，只用于观察训练过程中的 reward scale 是否稳定形成。

训练日志显示，该差异来自 reward scale 未能稳定形成，评测脚本和 source-level 统计未发现单点异常。

训练 run	最后 512 step 平均 score gap	最后 512 step positive gap rate	最后 512 step 平均 loss	full accuracy
PromptCap50 seed=42	0.3411	63.67%	0.6208	71.69%
PromptCap50 seed=123	0.0008	50.98%	0.6975	61.27%

这里的 score gap 是 score_chosen - score_rejected。主模型在最后 512 step 仍保持正向 score gap；seed=123 诊断实验的 score gap 接近 0，说明该次从头训练没有形成稳定排序尺度。这个结果不改变已保存主模型 checkpoint 的推理结果，但提示后续从头重训时应加入 warmup、gradient clipping、checkpoint selection 和多 seed 验证。

这一稳定性实验为后续改进提供了明确方向：当前 checkpoint 已经可以作为研究型可交付模型使用，单 epoch LoRA reward 训练仍存在优化敏感性。进一步提升模型时，优先工作应放在降低学习率、加入 warmup、使用 gradient clipping、保存中间 checkpoint 做选择以及多 seed 复现实验上。

6. 结果来源分析

与文档中的 base model 和 reward model 参考结果相比，本项目 70% 以上的结果主要来自任务形式、训练数据和基础模型能力三方面的共同作用。

第一，Score_base 和 Score_reward 的任务形式不同。Score_base 中，原始 VLM 需要生成自然语言判断结果；Score_reward 中，训练后的 reward model 直接比较两个数值分数。数值打分形式更贴近回答排序任务。

第二，训练数据是同域公开 preference data。RLAIF-V 和 VLRewardBench 都涉及视觉语言回答偏好、图像描述、视觉问答和幻觉相关判断。本文没有使用 VLRewardBench 的样本、标签或候选回答训练，但 RLAIF-V 与 benchmark 所在任务生态相近，这是模型提升的重要来源。

第三，InternVL2.5-2B 已经具备较强图文理解能力。LoRA reward 训练把已有表征重新对齐到“比较两个回答质量”这个任务上。对于 2B 级 VLM 来说，reward scoring 是更直接的优化目标。

综合来看，在不使用 VLRewardBench 训练样本和标签的前提下，基于 RLAIIF-V 同域偏好数据训练出的 InternVL2.5-2B reward model，可以在 VLRewardBench 上取得较强的回答偏好判断效果。数据相似性、prompt/source 分布和训练随机性也会明显影响分数，这也是本文后续数据实验和稳定性实验的主要依据。

7. 工程实现与实验组织

本项目从相对干净的远程环境开始，先完成模型、数据、依赖和代码路径的整理，再开展训练、评测和报告生成。最终目录约定如下。

类型	路径
基础模型	/root/private_data/models/reward-model-exam/OpenGVLab/InternVL2_5-2B
RLAIIF-V 数据	/root/private_data/datasets/reward-model-exam/rlaif-v
VLRewardBench 数据	/root/private_data/datasets/reward-model-exam/VL-RewardBench
项目代码	/root/private_data/projects/reward model
主模型 checkpoint	outputs/checkpoints/D_PromptCap50NoBench_4k_Linear
评测 summary	outputs/eval/D_PromptCap50NoBench_4k_Linear_vlrb_full_summary.json
报告图表	artifacts/figures/data-centric/

实验在 SCNet 超算互联网平台的 NVIDIA A800 80GB 环境上完成。训练和 full benchmark 评测都通过 tmux 离线运行；长时间任务挂在后台后，可以同步开展数据分析、图表生成和报告整理。每个重要实验都保留了训练日志、评测 summary、数据选择 indices 和 CSV 汇总，后续能够直接追溯训练配置和评测结果。

从时间组织上看，5 月 18 日先完成环境、base judge、head-only 和 raw 1k LoRA 实验；5 月 19 日至 20 日集中进行数据审计、PromptCap10/20/50 和结构消融；随后整理 source-level 结果、稳定性诊断、图表和权重包。这样的节奏使项目在早期就形成了可交付 checkpoint，后续实验继续补充结果解释和报告证据。

核心代码文件如下。

文件	作用
src/internvl_reward.py	InternVL reward model 封装
scripts/train_reward_head.py	reward head / LoRA 训练
scripts/eval_reward_head.py	VLRewardBench 数值打分评测
scripts/build_prompt_cap_indices.py	PromptCap 数据选择
scripts/data_similarity_and_diversity_audit.py	数据相似性和多样性审计
scripts/plot_data_centric_figures.py	报告图表生成

实验组织上，所有尝试被整理为三条线：

实验线	内容	作用
基础链路	head-only、LoRA raw1k、base judge、full eval	确认 reward model 训练和评测闭环
数据线	overlap audit、strict query+image、PromptCap10/20/50、source-level 分析	解释高分来源，选择主提交模型
结构线	MLP head、final+mean concat pooling、不同 seed	判断复杂结构是否必要，检查训练稳定性

这样的组织方式使实验结论从最高分扩展到分数来源、数据边界和方法稳定性三个层面。

8. 合规性说明

实验边界如下，便于复现和核查。

- 1 训练样本来自 RLAIIF-V，没有把 VLRewardBench 的样本、human ranking 或候选回答作为训练样本。
- 2 benchmark-aware 的 strict query+image 过滤只作为审计消融，用来理解显式相似性影响；最终主提交模型 PromptCap50 的训练子集选择不依赖 VLRewardBench 字段。
- 3 没有抄袭网络上已有 reward model 项目代码；训练、评测、数据审计和图表脚本均为本项目实现。
- 4 使用公开基础模型和公开训练数据；提交权重为 LoRA adapter + score head，基础模型权重通过 OpenGVLab/InternVL2_5-2B 加载。
- 5 低于预期的实验和稳定性分析也被整理进结果部分，用来呈现完整的实验链路和方法边界。

9. 当前结论与展望

最终提交模型为 **D-PromptCap50NoBench-4k-Linear**。该模型的 Score_reward 为 71.69%，相比 Score_base 46.51% 有明显提升。raw RLAIIF-V 1k 的 74.66% 展示了强同域适配的上限效果；PromptCap50 则在保持较高分数的同时降低了 prompt 模板集中度，因此构成本文的主模型结果。

实验中最清晰的一条线索来自数据分析。RLAIIF-V 这类同域偏好数据对多模态 reward model 非常有效，但数据子集的 prompt 分布、source 结构和训练稳定性会显著影响结果。PromptCap50 在分数和可解释性之间取得了较好的平衡：训练子集构造只使用 RLAIIF-V 内部统计，同时降低了 raw 子集的 prompt 集中度，并保持了 70% 以上的 full benchmark accuracy。

后续工作可以沿三个方向展开。首先是优化稳定性：基于当前诊断实验，进一步尝试 $5e-5$ 学习率、warmup、gradient clipping、更多训练 epoch 和 checkpoint selection。其次是多 seed 验证：通过至少 3 个随机种子估计 PromptCap50 的平均分和方差，使最终结论更稳健。最后是数据配比分析：进一步统计不同 PromptCap 设置下的 source 变化，解释 PromptCap20 低点和 PromptCap10 source-level 不均衡现象。完成这些稳定性和数据问题分析后，再继续探索 margin loss、多 head 或 response-length calibration 等结构和训练 trick。

参考文献

- [1] Liu, C., et al. Skywork-Reward: Bag of Tricks for Reward Modeling in LLMs. arXiv:2410.18451, 2024. <https://arxiv.org/abs/2410.18451>
- [2] Zhang, P., et al. InternLM-XComposer2.5-Reward. arXiv:2501.12368, 2025. <https://arxiv.org/abs/2501.12368>
- [3] Li, L., et al. VLRewardBench: A Challenging Benchmark for Vision-Language Generative Reward Models. arXiv:2411.17451, 2024. <https://arxiv.org/abs/2411.17451>
- [4] Yu, T., et al. RLAIIF-V: Aligning MLLMs through Open-Source AI Feedback for Super GPT-4V Trustworthiness. arXiv:2405.17220, 2024. <https://arxiv.org/abs/2405.17220>

附录 A：主模型训练命令

```
cd "/root/private_data/projects/reward model"
source scripts/activate_env.sh

python -u scripts/train_reward_head.py \
  --include-indices artifacts/report_assets/rlaifv_promptcap50_nobench_4k.indices.txt \
  --epochs 1 \
  --max-tiles 2 \
  --lr 1e-4 \
  --use-lora \
```

```
--lora-r 8 \  
--lora-alpha 16 \  
--lora-dropout 0.05 \  
--score-head-type linear \  
--pooling final \  
--output-dir outputs/checkpoints/D_PromptCap50NoBench_4k_Linear \  
--log-path outputs/logs/train_D_PromptCap50NoBench_4k_Linear.jsonl
```

附录 B：主模型评测命令

```
cd "/root/private_data/projects/reward_model"  
source scripts/activate_env.sh  
  
python -u scripts/eval_reward_head.py \  
--score-head outputs/checkpoints/D_PromptCap50NoBench_4k_Linear/score_head_final.pt \  
--lora-adapter outputs/checkpoints/D_PromptCap50NoBench_4k_Linear/lora_final \  
--limit 0 \  
--max-tiles 2 \  
--score-head-type linear \  
--pooling final \  
--output outputs/eval/D_PromptCap50NoBench_4k_Linear_vlrb_full.jsonl \  
--summary outputs/eval/D_PromptCap50NoBench_4k_Linear_vlrb_full_summary.json
```

附录 C：Hugging Face 权重包

最终权重包已经整理为：

```
outputs/hf_upload/internvl2-5-2b-vl-reward-model
```

其中包含：

```
README.md  
config.json  
training_meta.json  
score_head_final.pt  
lora_final/adapter_config.json  
lora_final/adapter_model.safetensors
```

该权重包不包含完整基础模型，不能脱离 OpenGVLab/InternVL2_5-2B 单独推理。使用时需要先加载基础模型，再加载 LoRA adapter 和 `score_head_final.pt`；完成这三部分加载后，可以用于 VLRewardBench 式的候选回答打分推理。